

Relatório - Mineração de Dados Aplicada

Luis Antonio Duarte Sousa
luisduarte.dev@gmail.com

Lucas Rios Bicalho
lucas-rb@ufmg.br

Thales Henrique Silva
thaleshenrique@ufmg.br

Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte - MG - Brasil

6 de agosto de 2024

1 Introdução

Motivação

A análise de dados está sendo realizada no contexto da indústria de jogos, especificamente focando na plataforma Steam, que é uma das maiores distribuidoras digitais de jogos para PC. A Steam hospeda uma vasta gama de jogos, desde grandes títulos AAA até jogos independentes (indie). Esse mercado é extremamente competitivo e dinâmico, com novos jogos sendo lançados constantemente, cada um competindo pela atenção e engajamento dos jogadores.

Neste projeto, estamos minerando dados de jogos na Steam para entender melhor as características que influenciam o sucesso e a popularidade dos jogos. A análise envolve explorar diversas variáveis, como número de jogadores atuais, picos de jogadores, avaliações dos usuários, gêneros dos jogos, e outros fatores relevantes. Compreender esses aspectos é crucial para desenvolvedores, publicadores e profissionais da indústria que buscam maximizar o impacto de seus lançamentos e estratégias de marketing.

Os dados específicos foram escolhidos para análise com o objetivo de descobrir tendências e tomar decisões informadas dentro da indústria de jogos. A motivação principal é entender quais fatores contribuem para o sucesso de um jogo na plataforma Steam. Isso inclui identificar quais gêneros são mais popula-

res, como os padrões de avaliação dos usuários influenciam a percepção do jogo, e como as características demográficas dos jogos (como a gratuidade e a presença de modos multiplayer) afetam seu desempenho.

Ao descobrir essas tendências, os desenvolvedores de jogos podem otimizar seus produtos para melhor atender às preferências dos jogadores, aumentar a retenção de jogadores e, em última análise, melhorar as vendas e o engajamento. Além disso, as informações derivadas desta análise podem ajudar os publicadores a tomar decisões mais estratégicas sobre marketing e lançamento de novos títulos, bem como identificar áreas para inovação e desenvolvimento. Assim, a análise não apenas revela insights valiosos sobre o comportamento dos jogadores, mas também fornece uma base sólida para decisões estratégicas no competitivo mercado de jogos.

Dados

A partir dos dados disponíveis no [SteamDB](#), foi realizado um web scraping para obter informações sobre os 5000 jogos mais jogados, incluindo a quantidade de jogadores e o SteamID de cada jogo. Em seguida, utilizando o SteamID, foram feitas requisições à API da Steam para obter um dicionário com informações variadas sobre cada jogo. Além disso, com o SteamID, acessamos a página da Steam de cada jogo para coletar análises e marcadores de cada produto,

informações que não estão disponíveis na API. Finalmente, todos esses dados foram agregados em uma tabela e salvos no arquivo `infoJogos.pkl`. Originalmente, o dataset contava com 5000 linhas e 19 colunas, sendo estas:

- **num**: Um identificador único para cada jogo.
- **nome**: O nome do jogo.
- **currentPlayers**: Número atual de jogadores ativos.
- **peak24h**: Pico de jogadores nas últimas 24 horas.
- **allTimePeak**: Pico de jogadores de todos os tempos.
- **gameID**: Identificador único do jogo na plataforma.
- **tags**: Lista de tags ou etiquetas descritivas associadas ao jogo (ex: gênero, estilo de jogo).
- **analises recentes texto**: Texto resumando as análises recentes dos usuários.
- **analises recentes qtd**: Número de análises recentes.
- **analises recentes positivas**: Porcentagem de análises recentes positivas.
- **analises totais texto**: Texto resumando as análises totais dos usuários.
- **analises totais qtd**: Número total de análises.
- **analises totais positivas**: Porcentagem de análises totais positivas.
- **tipo**: Tipo de produto (ex: jogo).
- **gratuito**: Indicador se o jogo é gratuito (True/-False).
- **idade**: Classificação etária do jogo.
- **generos**: Lista de gêneros do jogo.
- **categorias**: Lista de categorias do jogo.
- **lançamento**: Data de lançamento do jogo.

Uma quantidade significativa de jogos possuía algum ou todos os atributos nulos. Isso foi causado por elementos incomuns nas páginas individuais de cada jogo assim prejudicando a requisição. Dito isso, para mitigar esse problema era necessário remoção deles nos processamentos individuais.

Para conseguir alguns dos atributos acima foi necessário retirá-los do dicionário bruto que estava concentrando todo o html das páginas dos jogos em uma única coluna. Isso foi resolvido com alguns scripts,

formatações e conversões, assim, redirecionando os dados para colunas individuais para serem processados.

2 Análises

2.1 Classificação

2.1.1 Objetivo/Questão

O objetivo deste estudo é explorar a aplicação da teoria da informação para classificar jogos como multiplayer ou não, utilizando uma abordagem semelhante ao jogo das 20 perguntas. A hipótese é que é possível usar a intuição baseada na teoria da informação, que enfatiza a divisão do espaço de possíveis respostas, para prever a classificação de um jogo com base nas suas tags. Em termos de teoria da informação, cada pergunta feita no jogo das 20 perguntas é projetada para maximizar a redução da incerteza ou entropia sobre a identidade do objeto, dividindo o espaço de respostas em dois grupos de tamanho aproximadamente igual. Da mesma forma, a árvore de decisão criada neste estudo visa identificar se um jogo é multiplayer ou não, aproveitando o conceito de maximização da informação obtida a partir das tags disponíveis para reduzir a incerteza na classificação.

2.1.2 Metodologia

Para testar a hipótese, foram seguidos os seguintes passos:

1. **Preparação dos Dados**: Foram removidas as tags `Singleplayer`, `Multiplayer` e quaisquer tags contendo `online` ou `multiplayer`.
2. **Criação de Matrizes**: Para as tags restantes, foi criada uma matriz (denominada **X**) com codificação one-hot, onde cada coluna representa uma tag e cada linha representa um jogo. Uma matriz similar (denominada **Y**) foi criada para a tag `Multiplayer` removida.
3. **Classificação**: Utilizou-se uma árvore de decisão, configurada com profundidade máxima de 20, para classificar os jogos. Essa configuração é conceitualmente similar ao jogo das 20 perguntas.
4. **Avaliação**: Foi realizado um estratificado k-fold para analisar o overfitting, utilizando o f1 score como métrica de qualidade. O número ideal de elementos mínimos em um nó-folha foi testado, e a f1 score foi maximizada com folhas contendo cerca de 50 elementos.

5. **Geração de Modelo Final:** Com base nos resultados da validação, foi gerada uma nova árvore de decisão utilizando todo o dataset.




Figura 1: Árvore de decisão (uma versão legível está disponível no anexo)

2.1.3 Qualidade

A métrica de qualidade utilizada foi o F1 score. Ele foi escolhido por equilibrar a precisão e a recuperação, fornecendo uma avaliação robusta da capacidade da árvore de decisão em classificar corretamente os jogos como multiplayer ou não.

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (1)$$

Onde:

- Precision = $\frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$
- Recall = $\frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$

2.1.4 Análise dos Resultados

Os resultados indicam que a árvore de decisão foi capaz de tomar decisões intuitivas para classificar jogos como multiplayer ou não. A árvore começou com perguntas sobre tags como "Co-op", "PvP" e "Competitivo", levando a sub-árvores que foram predominantemente "Com multiplayer" ou "Sem multiplayer". Se o jogo não tinha essas tags, a árvore perguntava sobre características como "2D", "ação" e "simulação". Essa abordagem de questionamento revelou-se eficaz, mostrando que a ordem das perguntas baseada nas

tags pode melhorar significativamente a classificação em um cenário similar ao jogo das 20 perguntas.

Observa-se na figura 2 que o F1 score foi maximizado com cerca de 40 elementos por folha. Aumentar a quantidade de folhas além disso fez a métrica piorar.




Figura 2: F1 score por número de folhas

2.2 Agrupamento (Clustering)

2.2.1 Objetivo/Questão

Pergunta: "Quais são os diferentes grupos de jogos baseados em suas características e o que elas revelam sobre usuários?"

A intenção dessa análise é buscar grupos do público usuário da plataforma de jogos *STEAM* onde sua **similaridade** interna (intra-cluster) seja maximizada e externa (inter-cluster) minimizada.

2.2.2 Metodologia

• Pré-processamento:

- **Remoção de o que não é jogo:** Inicialmente através da coluna booleana '*tipo*' todos os Objetos do dataset que não eram jogos foram **excluídos** para manter o foco da análise em jogos. Eles representam 6% dos dados.

- **Seleção de Atributos:** Os atributos inicialmente selecionados para essa análise foram: *nome*, *currentPlayers*, *peak24h*, *allTimePeak*, *gameID*, *tags*, *analisesRecentesTexto*, *analisesRecentesQtd*, *analisesRecentesPositivas*, *analisesTotaisTexto*, *analisesTotaisQtd*, *analisesTotaisPositivas*, *tipo*, *gratuito*, *idade*, *generos*, *categorias* e *lançamento*. Entretanto, observando-se melhor o conteúdo de cada uma foram **descartados** atributos irrelevantes para a análise




Figura 3: Proporção entre jogos e não jogos

como: *tipo*, *num*, *gameID*, *analisesTotaisTexto*, *analisesRecentesPositivas*, *analisesRecentesQtd* e *analisesRecentesTexto*.

- **Padronizar *idade*:** A coluna '*idade*' havia linhas fora do padrão previsto como por exemplo '17+', o que causava problemas na conversão para inteiro. Logo, foi necessário uma função para remoção de caracteres especiais da coluna.

- **Criação de nova coluna advinda de *tags*:** A coluna booleana '*tem_multiplayer*' foi criada extraindo dos jogos que possuíam multiplayer ou massively multiplayer como uma de suas tags. O objetivo era adicionar ela no calculo do cluster pois é um dado importante sobre a popularidade.

- **Exclusão de atributos redundantes:** As colunas '*tags*', '*categorias*' e '*generos*' possuem informações muito parecidas e alguma até redundantes como por exemplo duas delas ter "Multiplayer". Dito isso, foi mantido apenas a coluna '*generos*' que de forma sucinta descreve o jogo. Além disso evita também aumento de atributos e consequentemente maldição da dimensionalidade.

- **Criação de nova coluna advinda de *lançamento*:** As datas de lançamento dos jogos foram mineiradas em um formato difícil de se converter para **datetime** uma vez que existiam várias formas que as datas estavam escritas. Dito isso, extraiu-se apenas o ano da data para uma nova coluna '*ano_lancamento*' excluindo-se o restante dos dados.

- **Nova Coluna Baseada em '*peak24h*' e '*allTimePeak*':** A coluna '*proporção jogadores*

restantes' foi gerada a partir de

$$\frac{Peak24}{AllTimePeak} \quad (2)$$

E representa a taxa de queda/aumento na proporção dos jogadores desde o maior pico do jogo. Além disso, '*peak24h*' e '*allTimePeak*' tinham uma alta correlação, consequentemente gerando multicolinearidade. Então, após a criação desse novo dado ambas foram descartadas.

- **Nova Coluna Baseada em '*analisesTotaisQtd*', '*analisesTotaisPositivas*' e '*CurrentPlayers*':** A coluna '*numero_de_analises_positivas*' foi gerada a partir de

$$\frac{analisesTotaisQtd * \frac{analisesTotaisPositivas}{100}}{CurrentPlayers} \quad (3)$$

Uma vez que *analisesTotaisPositivas* se trata de uma proporção foi necessário a divisão por 100 e além disso a divisão por *CurrentPlayers* se justifica pelo fato de que quanto mais player mais análises, logo é necessário uma normalização.

- **Exclusão de nulos:** Os nulos foram retirados das colunas '*generos*', '*analisesTotaisQtd*', '*analisesTotaisPositivas*' e '*ano_lancamento*'. Representando 1.3 % dos dados.




Figura 4: Nulos

- **Normalização utilizando Min-Max:** As colunas foram devidamente normalizadas utilizando

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (4)$$

A escolha do min-max se deve pelo fato de que o intervalo dos valores numéricos muitas vezes era muito grande e se distanciava de uma distribuição normal. Além disso, essa normalização tem melhor interpretabilidade e mantém todos os valores entre $[0-1]$ evitando valores absurdos de escala.

- **Transformação dos booleanos em inteiros:** As colunas booleanas *'tem_multiplayer'* e *'gratuito'* foram convertidas de True/False para 1/0 para aplicação dos algoritmos.

- **Redução de Dimensionalidade:** Ao final da normalização temos 7 atributos para fazer o clustering




Figura 5: Histograma




Figura 6: Matriz de correlação por calor

A figura 5 mostra os histogramas com a distribuição de valores após as normalizações. Por sua vez, a figura 6 contém a matriz de correlação. É visível que não existe nenhum problema de

multicolinearidade. Além disso, os nulos foram retirados anteriormente também evitando problemas com nulos. Portanto, analisando-se as distribuições não haverá problemas na utilização de PCA (Principal Component Analysis) para redução de dimensionalidade, assim, permitindo melhor visualização dos dados em 3 dimensões.

• Algoritmos

- **Aglomeracão Hierárquica:** O algoritmo com hiperpâmetro linkagem **completa** (Distância máxima entre dois clusters) serviu para auxiliar na visualização pelo dendograma um bom valor para um numero K de clusters a ser buscado no K-Means.




Figura 7: Dendograma

- **K-Means:** Utilizamos o algoritmo KMeans para agrupar os dados em clusters esféricos. Escolhemos um número de k clusters baseado no método do cotovelo, dendograma e na silhueta. Os hiperparâmetros são o número de clusters e seleção inicial aleatória dos centróides. O melhor k encontrado foi 5 com boa estabilidade e score mais alto.

2.2.3 Qualidade

Para averiguar a qualidade dos clusters e ajudar na decisão do numero k foram usados os métodos:

- **Inércia (Within-cluster sum of squares):** Utilizada para determinar o número ideal de clusters. Avalia a soma das distâncias quadráticas dos pontos aos seus centróides dentro de cada cluster.
- **Silhouette Score:** Utilizada para avaliar a qualidade dos clusters formados. Mede o quão semelhantes os pontos são aos seus próprios clusters




Figura 8: Inércia e Silhueta

comparados aos clusters vizinhos.

2.2.4 Análise dos Resultados

Os resultados após PCA e clusterização com hiperâmetro 5 podem ser visualizados em uma imagem tridimensional:




Figura 9: Clusteres

• Cluster 0

- **Gêneros Predominantes:** Free to Play, Action, Massively Multiplayer, Indie, Strategy.

- **Características Numéricas:**

- Representa 12.4% da amostra.
- Alta proporção de jogos gratuitos.




Figura 10: Cluster 0

- Jogos com idade mínima média relativamente baixa.
- Maior concentração de jogadores atuais.
- Maioria dos jogos são multiplayer.
- Ano de lançamento recente.
- Média de perda de jogadores é 74%.
- Avaliações mistas.

- Padrões Interessantes:

- Predominância de jogos Free to Play e multiplayer, sugerindo que esses jogos são mais acessíveis e populares entre os jogadores que preferem não gastar ou não podem gastar, como crianças.
- Concentram mais jogadores que 80% dos jogos pela sua acessibilidade e possibilidade de multiplayer.
- Alta concentração de jogos de ação e massivamente multiplayer, indicando uma preferência por experiências de jogo dinâmicas e interativas.

- Exemplos: Dota 2 e PUBG

• Cluster 1

- **Gêneros Predominantes:** Indie, Adventure, RPG, Action.

- **Características Numéricas:**

- Representa 46.3% da amostra.
- Maioria dos jogos são pagos.
- Jogos com idade mínima média relativamente baixa.
- Baixa concentração de jogadores atuais.
- Maioria dos jogos são single-player.




Figura 11: Cluster 1

- Ano de lançamento recente.
- Média de perda de jogadores é 83%.
- Avaliações boas.

- **Padrões Interessantes:**

- A prevalência de jogos indie e de aventura indica uma preferência por experiências únicas e narrativas fortes.
- Esses jogos são mais voltados para experiências single-player de apenas uma experiência temporária e única, onde o jogador compra, diverte-se e não joga mais. Isso é comum na maioria dos jogos da Steam.

- Exemplos: Fallout 4 e God of War

• Cluster 2




Figura 12: Cluster 2

- **Gêneros Predominantes:** Action, Indie, Simulation, Strategy.

- **Características Numéricas:**

- Representa 27.4% da amostra.
- Maioria dos jogos são pagos.

- Idade livre.
- Boa concentração de jogadores atuais.
- Maioria dos jogos são multiplayer.
- Inclui jogos mais antigos, mas a maioria são recentes.
- Média de perda de jogadores é 85%.
- Avaliações boas.

- **Padrões Interessantes:**

- Forte presença de jogos de ação e indie, sugerindo que esses jogos são populares tanto para experiências intensas quanto criativas.
- A alta proporção de jogos multiplayer indica uma preferência por jogos colaborativos ou competitivos.

- Exemplos: Stardew Valley e EA SPORTS FC™ 24

• Cluster 3




Figura 13: Cluster 3

- **Gêneros Predominantes:** Free to Play, Indie, Casual, Strategy, Simulation.

- **Características Numéricas:**

- Representa 8% da amostra.
- Alta proporção de jogos gratuitos.
- Idade livre.
- Baixa concentração de jogadores atuais.
- Maioria dos jogos são single-player.
- Jogos muito mais recentes.
- Média de perda de jogadores é 69%.
- Avaliações mistas.

- **Padrões Interessantes:**

- Predominância de jogos casuais e gratuitos, indicando uma preferência por jogos acessíveis e de fácil entrada.
- Jogos de uma experiência única de enredo, mas fora do comum e gratuitos.
- Exemplos: Magic Rampage e Grimm's Hollow

• Cluster 4




Figura 14: Cluster 4

- **Gêneros Predominantes:** Action, Adventure, RPG, Strategy.
- **Características Numéricas:**
 - Representa 5.6% da amostra.
 - Maioria dos jogos são pagos.
 - Alta idade.
 - Alta média de jogadores atuais.
 - Maioria dos jogos são multiplayer.
 - Jogos recentes, mas com muitos antigos.
 - Média de perda de jogadores é 91%.
 - Avaliações muito boas.
- **Padrões Interessantes:**
 - Forte presença de jogos de ação e aventura, indicando uma preferência por jogos com elementos narrativos e de ação.
 - Alta média de jogadores atuais, sugerindo uma base de jogadores ativa e engajada.
- Exemplos: Grand Theft Auto V e Call Of Duty

Os resultados foram melhores do que o esperado, uma vez que os clusters conseguiram ser bem únicos e transferir informações interessantes.

O Cluster 0 agrupou os jogos mais jogados da Steam, que mantêm mais de 80% dos jogadores ativos. Uma característica comum desses jogos é a gratuidade

e o multiplayer, demonstrando que eles atendem a usuários que buscam uma experiência competitiva/-cooperativa de todas as formas e até mesmo aqueles com renda baixa, tornando esses jogos inclusivos. As avaliações mistas e a perda de jogadores refletem uma toxicidade na comunidade, uma vez que jogos nesse formato possuem muitos conflitos internos dentro de sua própria comunidade.

O Cluster 1 agrupou jogos focados em história que buscam desenvolver uma experiência single-player em que o usuário desfrute de um enredo único e de boa qualidade. Pelo fato de esses jogos não terem muitas microtransações, eles são pagos, mas bem avaliados. A baixa quantidade de jogadores atuais é justificada pelo fato de jogos assim serem normalmente jogados apenas uma vez.

O Cluster 2 agrupou jogos multiplayer mais casuais pagos que desenvolvem um cenário imersivo e criativo de cooperação/competitividade. Esses jogos normalmente têm uma base de jogadores antiga que busca experiências bem específicas, normalmente relacionadas com hobbies, relaxamento ou apenas diversão. Suas avaliações são boas e eles conseguem manter muitos jogadores ativos.

O Cluster 3 agrupou jogos independentes e pequenos, normalmente desenvolvidos por pessoas que estão começando na criação e modelagem de jogos e distribuem seus jogos de forma gratuita para avaliação do público. Esses jogos possuem ou não pequenos enredos single-player e normalmente são muito inovadores, com características únicas. Além disso, eles são curtos, o que explica a pequena quantidade de jogadores ativos.

O Cluster 4 agrupou jogos pagos, violentos, com classificação mais alta e focados no multiplayer competitivo. Esses jogos também possuem uma base de jogadores muito específica e se diferenciam pelas suas avaliações muito altas. No geral, esses jogos tentam mesclar um enredo com um multiplayer imersivo de competição entre os jogadores.

Em resumo, cada cluster identificou padrões distintos entre os jogos, revelando preferências variadas entre os jogadores, desde experiências acessíveis e cooperativas até aventuras single-player bem avaliadas e jogos independentes inovadores. Esses insights podem ser valiosos para desenvolvedores e profissionais da indústria ao planejar e desenvolver novos jogos.

2.3 Itens Frequentes

2.3.1 Objetivo/Questão

Os marcadores, escolhidos pelos usuários, podem ser redundantes. Desejamos identificar quais são os mais redundantes.

Identificar marcadores redundantes pode melhorar a categorização dos jogos, tornando a busca e a descoberta mais eficazes. Isso resulta em uma melhor experiência do usuário e em recomendações mais precisas, além de otimizar a indexação e a navegação nas plataformas de jogos.

Com esta abordagem, podemos identificar e analisar a redundância dos marcadores de maneira sistemática e fundamentada, contribuindo para a melhoria contínua das plataformas de jogos.

2.3.2 Metodologia

- Extração dos Marcadores:** Inicialmente, extraímos todos os marcadores dos jogos.
- Geração de Regras de Associação:** Criamos regras de associação do tipo "Tag A $\rightarrow$ Tag B", onde a presença de B em um jogo indica redundância.
- Suporte Mínimo:** Estabelecemos um suporte mínimo de 0,01. Isso significa que, mesmo que poucas regras atendam a este critério, serão analisadas.
- Confiança Mínima:** Definimos uma confiança mínima de 0,9. Ou seja, para 90% dos jogos que possuem a tag A, a tag B também deve estar presente. Se a regra for válida para menos de 90% dos jogos, a presença da tag B não é considerada tão redundante.
- Ordenação pelo Lift:** Das regras de associação encontradas, ordenamos pelo Lift, que indica se a Tag A tem correlação positiva com a Tag B, mostrando que a redundância não é meramente por acaso.

2.3.3 Qualidade

Como já dito acima, para avaliar a qualidade dos resultados, usamos regras de associação para identificar marcadores redundantes. O suporte garante que mesmo regras com poucos exemplos sejam consideradas, enquanto a confiança assegura que a tag consequente aparece em 90% dos jogos com a tag antecedente. Ordenamos as regras pelo lift para confirmar que a redundância não é aleatória.

2.3.4 Análise dos Resultados

A análise revelou várias redundâncias nos marcadores, especialmente nas regras do tipo "Tag A $\rightarrow$ Tag B" quando A é semanticamente um subconjunto de B. Por exemplo, "Simulador espacial" é um subconjunto de "jogos espaciais", e "Deckbuilder roguelike" é um subconjunto de "deckbuilder". Além disso, tags como "CRPG", "JRPG" e "Party-based RPG" são subconjuntos da tag mais geral "RPG". Observou-se também que algumas redundâncias ocorrem devido a tags com significados muito similares, como "NSFW", "Nudity" e "Sexual content", que frequentemente se sobrepõem. Os resultados ordenados pelo lift (na forma lhs $\rightarrow$ rhs) podem ser vistos nas figuras 15 e 16.

É possível concluir que muitas redundâncias nos marcadores ocorrem devido a relações de subcategorias e sobreposição de significados semelhantes. Para melhorar a eficácia da categorização e recomendação de jogos, seria importante revisar e consolidar essas tags redundantes. Isso poderia simplificar a estrutura de marcadores e a otimizar a busca e descoberta de jogos, aprimorando a experiência do usuário.

	lhs	rhs	lift	count rhs	count lhs	count full
0	[Space Sim]	[Space]	17.565509	260	62	58
1	[Roguelike Deckbuilder]	[Roguelike]	11.207530	396	55	50
2	[NSFW]	[Nudity]	10.862783	409	189	172
3	[NSFW]	[Sexual Content]	9.672768	470	189	176
4	[Hentai]	[Sexual Content]	9.507891	470	189	173
5	[Open World Survival Craft]	[Survival]	6.813757	677	127	120
6	[Aliens]	[Sci-fi]	6.756268	664	111	102
7	[CRPG]	[RPG]	2.875367	1667	110	108
8	[Transportation]	[Simulation]	2.779500	1704	67	65
9	[JRPG]	[RPG]	2.778909	1667	313	297
10	[4X]	[Strategy]	2.769144	1763	113	113
11	[Grand Strategy]	[Strategy]	2.741172	1763	198	196
12	[Party-Based RPG]	[RPG]	2.735942	1667	152	142

Figura 15: Regras de Associação 1

3 Conclusão Geral

O trabalho permitiu praticar conceitos relacionados às três tarefas principais.

No caso da classificação, explorou-se a utilização da teoria da informação para categorizar jogos como multiplayer ou não, usando uma abordagem semelhante ao jogo das 20 perguntas. A árvore de decisão, construída para reduzir a incerteza sobre a classificação com base nas tags dos jogos, mostrou-se eficaz. A metodologia incluiu a preparação dos dados, criação de matrizes, e avaliação usando o F1 score,

13	[RTS]	[Strategy]	2.703385	1763	379	370
14	[Farming Sim]	[Simulation]	2.672417	1704	119	111
15	[Diplomacy]	[Strategy]	2.659835	1763	76	73
16	[Hex Grid]	[Strategy]	2.643273	1763	66	63
17	[Life Sim]	[Simulation]	2.627509	1704	193	177
18	[Roguelike Deckbuilder]	[Strategy]	2.618099	1763	55	52
19	[Economy]	[Simulation]	2.602979	1704	328	298
20	[Real Time Tactics]	[Strategy]	2.563514	1763	202	187
21	[Turn-Based Strategy]	[Strategy]	2.554187	1763	438	404
22	[Real-Time]	[Strategy]	2.517403	1763	77	70
23	[Online Co-Op]	[Multiplayer]	2.128154	2149	791	741
24	[Competitive]	[Multiplayer]	2.083365	2149	205	188
25	[Split Screen]	[Multiplayer]	2.080161	2149	83	76
26	[Co-op]	[Multiplayer]	2.066939	2149	1209	1100
27	[Shoot 'Em Up]	[Action]	2.011716	2387	61	60

Figura 16: Regras de Associação 2

que confirmou a precisão do modelo. Os resultados indicam que a árvore de decisão, configurada para maximizar a informação, conseguiu classificar os jogos de forma precisa, validando a hipótese de que técnicas baseadas na teoria da informação são úteis para problemas complexos de classificação.

Na análise de agrupamento dos jogos na plataforma Steam, identificamos cinco clusters distintos que revelam padrões variados nas preferências dos jogadores. O Cluster 0 inclui jogos gratuitos e multiplayer, muito jogados, mas com avaliações mistas e alta perda de jogadores. O Cluster 1 reúne jogos pagos e single-player com foco em narrativa, bem avaliados e com baixa quantidade de jogadores ativos. O Cluster 2 agrupa jogos casuais e pagos com boa recepção e alta concentração de multiplayer. O Cluster 3 consiste em jogos indie gratuitos, inovadores e com poucos jogadores ativos. Finalmente, o Cluster 4 abrange jogos pagos e violentos, com alta classificação e foco em multiplayer competitivo. Esses clusters destacam a diversidade de experiências de jogo e preferências dos usuários.

Por fim, foram identificados marcadores redundantes em jogos para melhorar a categorização e recomendação. Utilizando regras de associação com suporte mínimo de 0,01 e confiança mínima de 0,9, foi possível detectar redundâncias, como tags que são subconjuntos umas das outras ("Simulador espacial" e "Jogos espaciais") e tags com significados semelhantes ("NSFW" e "Nudity"). A análise sugeriu que revisar e consolidar essas tags pode aprimorar a experiência do usuário e otimizar a busca e categorização de jogos.

4 Referências

- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques*. Elsevier.
- Aggarwal, C. C. (2015). *Data Mining: The Textbook*. Springer.
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI magazine*, 17(3), 37–54. Association for the Advancement of Artificial Intelligence.